

UNIVERSIDAD DEL VALLE DE GUATEMALA

DATA SCIENCE · SECCIÓN 10 · GRUPO 1

Laboratorio 5

Minería de Textos y
Análisis de Sentimientos

Clasificación reproducible de tweets sobre desastres reales

Jorge Gabriel Palacios Sales	231385
Pablo Daniel Barillas Moreno	22193
Roberto Emiliano Otoniel	23968

Entrega final · 2026

[Repositorio oficial del Laboratorio 5](#)

Contents

1	Resumen ejecutivo	2
2	Objetivos	2
2.1	Objetivo general	2
2.2	Objetivos específicos	2
3	Datos y protocolo experimental	2
3.1	Fuente y estructura	2
3.2	Partición y métricas	3
4	Limpieza y representación	3
5	Frecuencias y n-gramas	4
6	Modelado supervisado	6
6.1	Modelos comparados	6
6.2	Función de clasificación	7
7	Análisis de sentimiento	8
7.1	Método	8
7.2	Tweets extremos	8
8	Contraste de negatividad	9
9	Reentrenamiento con negatividad	10
10	Análisis de errores y discusión	11
10.1	Limitaciones	11
11	Conclusiones	12
12	Reproducibilidad y trazabilidad	12
A	Correspondencia con la rúbrica	13

1 Resumen ejecutivo

Este trabajo desarrolla un flujo reproducible de procesamiento de lenguaje natural para identificar si un tweet describe un desastre real. Se analizaron las 7,613 observaciones etiquetadas de la competencia *Natural Language Processing with Disaster Tweets* de Kaggle [4]. El proceso incluye validación de datos, limpieza auditable, frecuencias y n-gramas por clase, análisis exploratorio, comparación de clasificadores, inferencia sobre texto crudo, análisis de sentimiento con VADER, contraste estadístico, ingeniería de una variable de negatividad y análisis de errores.

La regresión logística con TF-IDF de unigramas y bigramas fue seleccionada como modelo final. En una partición estratificada 80/20 alcanzó exactitud de 0.813, F1 de 0.781 para la clase desastre y ROC-AUC de 0.867. Los tweets de desastre tuvieron negatividad media de 0.337, frente a 0.213 en los demás; la diferencia fue estadísticamente significativa, aunque de magnitud pequeña. Agregar la negatividad al clasificador redujo el F1 a 0.764, por lo que esta variable no se incluyó en el modelo definitivo.

2 Objetivos

2.1 Objetivo general

Aplicar técnicas de minería de textos, aprendizaje automático y análisis de sentimiento para describir y clasificar tweets relacionados con desastres reales.

2.2 Objetivos específicos

1. Describir la estructura, calidad y distribución del conjunto de entrenamiento.
2. Diseñar una limpieza de texto explicable y reproducible.
3. Comparar vocabulario, unigramas, bigramas y trigramas entre clases.
4. Evaluar varios clasificadores bajo una partición común.
5. Implementar una función que reciba un tweet crudo y devuelva su clasificación.
6. Etiquetar el sentimiento como positivo, negativo o neutral, conservando emoticonos y señales de superficie.
7. comparar los diez tweets más positivos y negativos y determinar si los desastres se expresan con mayor negatividad.
8. Incorporar una variable cuantitativa de negatividad, reentrenar el modelo y medir su aporte incremental.

3 Datos y protocolo experimental

3.1 Fuente y estructura

El archivo principal es `data/raw/train.csv`, proveniente de Kaggle [4]. Su integridad se controla mediante SHA-256: 61111c6dc31eaffa34d1e1fa62e2395325c9bc3b38bba1941a5f1ed9b3fa60df.

Contiene las variables `id`, `keyword`, `location`, `text` y `target`. La variable objetivo vale uno cuando el tweet describe un desastre real y cero en caso contrario.

De las 7,613 observaciones, 4,342 (57.06%) pertenecen a la clase sin desastre y 3,271 (42.94%) a la clase desastre. Hay 61 valores ausentes en `keyword` y 2,533 en `location`; no hay valores faltantes en texto u objetivo. El archivo `test.csv` se conserva por trazabilidad, pero no se utiliza para evaluación porque no posee `target`.




Figure 1: Panorama del conjunto: distribución de clases, longitud del texto y variables faltantes.

3.2 Partición y métricas

Se realizó una separación estratificada con 80% para entrenamiento (6,090 tweets) y 20% para validación (1,523 tweets), usando semilla 42. Todos los modelos reciben exactamente las mismas observaciones. Debido al desbalance moderado se reportan exactitud, precisión, recall, F1 de la clase desastre, F1 macro y ROC-AUC. También se conservan las matrices de confusión.

4 Limpieza y representación

Para el clasificador se aplicaron los siguientes pasos:

1. conversión a minúsculas y normalización Unicode;
2. sustitución de URL y menciones por marcadores semánticos;

3. separación del símbolo de los hashtags para conservar su palabra;
4. eliminación de caracteres no informativos y reducción de espacios;
5. eliminación controlada de palabras vacías;
6. vectorización TF-IDF con unigramas y bigramas.

La implementación de la limpieza utiliza los módulos estándar `re`, `html` y `string`, junto con `ENGLISH_STOP_WORDS` de `sklearn.feature_extraction.text`. Para sentimiento se usa una normalización más ligera. No se eliminan negaciones, mayúsculas, signos de exclamación, emojis ni emoticonos, porque VADER utiliza esas señales para ajustar la intensidad [1]. El repositorio incluye `auditoria_limpieza.csv`, ejemplos antes/después y una auditoría de la lista Glasgow de palabras vacías. Esta última revela que términos temáticos como *fire* podrían ser eliminados; el efecto se declara como limitación y se mantiene constante en todas las comparaciones.

5 Frecuencias y n-gramas

Se calcularon conteos y probabilidades condicionales para unigramas, bigramas y trigramas dentro de cada clase. Los términos aislados permiten reconocer temas dominantes, mientras que los n-gramas recuperan contexto: una palabra como *disaster* puede aparecer en una emergencia o como metáfora. Las expresiones asociadas con evacuación, incendios, advertencias y daños se concentran en la clase positiva; en la negativa aparecen usos sociales, promocionales y figurados.

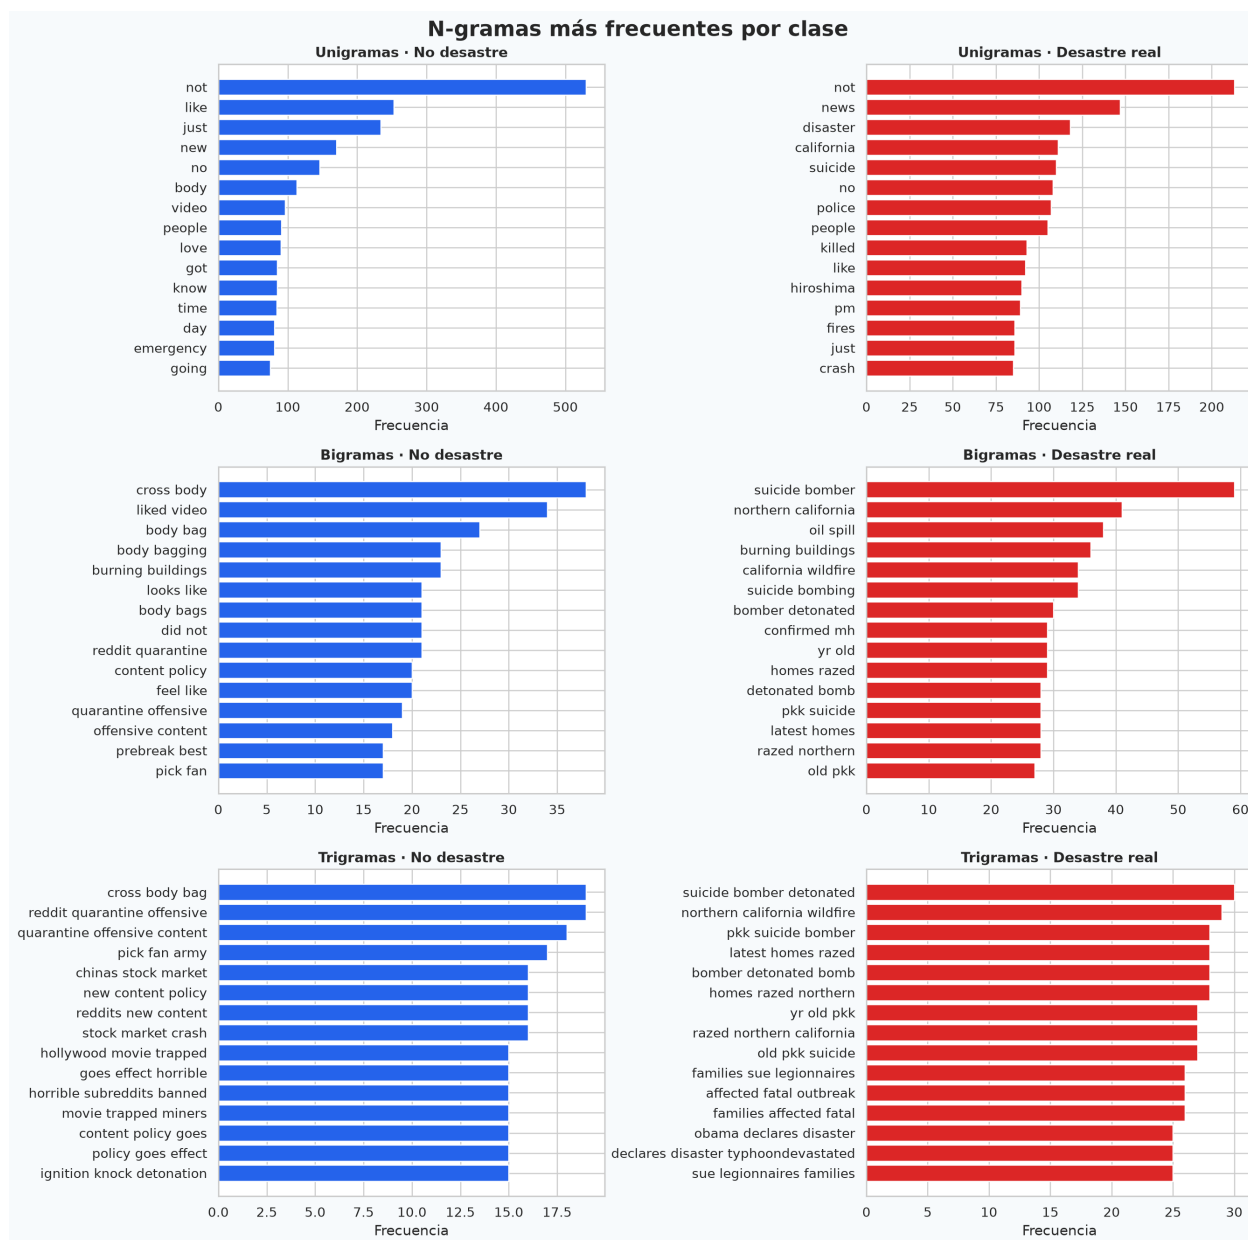


Figure 2: N-gramas principales por clase. Las probabilidades se calculan dentro de cada grupo.

Las nubes de palabras de la Figura 3 sirven como resumen visual, no como evidencia inferencial. La comparación cuantitativa se conserva en los CSV de outputs/tables.




Figure 4: Matrices de confusión de los modelos comparados.

6.2 Función de clasificación

La función `classify_raw_tweet` recibe un texto sin preprocesar. Internamente genera la versión limpia, calcula sentimiento y negatividad, ejecuta el pipeline persistido y devuelve clase, etiqueta, probabilidad de desastre y variables de sentimiento. El script `scripts/predict_tweet.py` expone esta funcionalidad desde la terminal. El modelo definitivo y su contrato se almacenan en `models/modelo_final.joblib` y `models/metadata_final.json`; por ello, la inferencia funciona inmediatamente después de clonar el repositorio.

7 Análisis de sentimiento

7.1 Método

VADER produce puntajes negativo, neutral, positivo y compuesto. Se usan los umbrales publicados por Hutto y Gilbert [1]: positivo si $compound \geq 0.05$, negativo si $compound \leq -0.05$ y neutral en el intervalo intermedio. La salida global contiene 3,747 tweets negativos, 1,971 positivos y 1,895 neutrales.




Figure 5: Distribución, intensidad y negatividad del sentimiento por clase.

El sentimiento no es sinónimo de desastre. Un reporte factual puede ser neutral y una publicación personal puede expresar fuerte negatividad sin describir una emergencia real. Esta separación conceptual motiva el experimento de aporte incremental de la Sección 9.

7.2 Tweets extremos

Se ordenó el corpus por `compound` y se seleccionaron los diez valores más altos y los diez más bajos. Siete de los diez extremos negativos corresponden a desastres; nueve de los diez extremos positivos son de la clase sin desastre. Los negativos contienen muerte, lesión, amenaza y destrucción. Los positivos concentran agradecimiento, apoyo, humor y mensajes promocionales. Las tablas completas preservan identificador, texto, clase y puntajes para que la interpretación sea verificable.




Figure 6: Composición por clase de los diez tweets más positivos y negativos.

8 Contraste de negatividad

Se definió una variable no negativa:

$$negativity_i = \max(-compound_i, 0).$$

El 50.28% de las observaciones tiene valor cero. Dada la masa en cero y la asimetría, se utilizó Mann–Whitney bilateral en vez de una prueba paramétrica. La diferencia de medias se complementó con un intervalo bootstrap del 95% y delta de Cliff como tamaño de efecto.

Table 2: Comparación de negatividad entre clases.

Indicador	Resultado
Media, desastre real	0.3366
Media, no desastre	0.2126
Diferencia de medias	0.1240
IC bootstrap 95%	[0.1099, 0.1382]
Valor p , Mann–Whitney	< 0.001
Delta de Cliff	0.2069 (pequeño)

El resultado respalda que los tweets de desastre son más negativos en distribución, pero la magnitud pequeña anticipa que la variable por sí sola no separará perfectamente las clases.




Figure 7: Contraste descriptivo e inferencial de la negatividad.

9 Reentrenamiento con negatividad

Se compararon dos pipelines bajo la misma división: A, regresión logística con TF-IDF; y B, la misma representación más **negativity**. No se cambiaron hiperparámetros ni observaciones.

Table 3: Efecto de incorporar la variable de negatividad.

Métrica	A: sin negatividad	B: con negatividad	Diferencia B-A
Exactitud	0.8129	0.7978	-0.0151
Precisión	0.7852	0.7662	-0.0190
Recall	0.7768	0.7615	-0.0153
F1	0.7809	0.7638	-0.0171
F1 macro	0.8088	0.7935	-0.0153
ROC-AUC	0.8666	0.8670	+0.0004
Falsos positivos	139	152	+13
Falsos negativos	146	156	+10

La mejora mínima de ROC-AUC no compensa el deterioro del resto de métricas. La negatividad probablemente es redundante con términos que TF-IDF ya representa. En consecuencia, el modelo final es A y se registra explícitamente que no usa la variable adicional.




Figure 8: Comparación controlada de desempeño con y sin negatividad.

10 Análisis de errores y discusión

El modelo final produce 139 falsos positivos y 146 falsos negativos. Los falsos positivos suelen contener vocabulario alarmante en contextos figurados, humorísticos o promocionales. Los falsos negativos incluyen mensajes breves, ubicaciones implícitas y reportes factuales cuyo tono no es abiertamente negativo.




Figure 9: Distribución de errores según sentimiento, negatividad y probabilidad estimada.

Los errores cercanos a probabilidad 0.5 representan ambigüedad esperable. Los errores de alta confianza son más relevantes: exhiben ironía, metáforas, titulares sin contexto y referencias que exigen conocimiento externo. Un modelo lineal con bolsa de palabras no comprende de forma explícita temporalidad, causalidad o sarcasmo.

10.1 Limitaciones

- El corpus fue construido para una competencia y puede no representar todas las emergencias, regiones o variedades lingüísticas.

- VADER fue diseñado para inglés y redes sociales; sus reglas no constituyen una medición clínica ni causal de emociones.
- Se utiliza una sola partición estratificada. La semilla fija permite reproducción, pero validación cruzada o un conjunto externo darían una estimación más estable.
- La lista estándar de palabras vacías elimina algunos términos de contenido; el fenómeno se auditó, pero futuros trabajos podrían diseñar una lista específica del dominio.
- La significancia estadística no implica utilidad predictiva, como demuestra el experimento con negatividad.

11 Conclusiones

1. La representación TF-IDF de unigramas y bigramas captura suficiente contexto para superar ampliamente el baseline.
2. La regresión logística alcanza el mejor F1 de la comparación y ofrece un modelo transparente, ligero y reproducible.
3. Los tweets de desastres reales son más negativos en promedio; la evidencia inferencial es fuerte, aunque el tamaño de efecto es pequeño.
4. La variable de negatividad no mejora el modelo: reduce exactitud, precisión, recall y F1. Por ello se excluye del clasificador definitivo.
5. El análisis de errores muestra que la principal frontera pendiente es semántica: ironía, lenguaje figurado y contexto ausente requieren representaciones más ricas.
6. El repositorio entrega código modular, notebook ejecutado, tablas, figuras, pruebas, modelo persistido, metadatos e informe, lo que permite verificar cada resultado.

12 Reproducibilidad y trazabilidad

El entorno se instala desde `pyproject.toml`, `uv.lock` o `requirements.txt`. El flujo se divide en cuatro comandos verificables:

- etapa base: `scripts/run_advance.py`;
- análisis y modelo final: `scripts/run_final.py`;
- notebook narrativo: `scripts/build_notebook.py`;
- inferencia individual: `scripts/predict_tweet.py`.

La suite automatizada comprueba fórmulas, limpieza, partición, contrato de resultados, persistencia del modelo y metadatos.

La tabla `outputs/tables/evidencia_rubrica.csv` enlaza cada criterio con archivos concretos y comprueba su existencia. El historial del código y los entregables está disponible en [Repositorio oficial del Laboratorio 5](#).

References

- [1] Hutto, C. J. y Gilbert, E. (2014). *VADER: A Parsimonious Rule-based Model for Sentiment Analysis of Social Media Text*. Proceedings of the International AAAI Conference on Web and Social Media.
- [2] Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.
- [3] Salton, G. y Buckley, C. (1988). *Term-weighting approaches in automatic text retrieval*. Information Processing & Management, 24(5), 513–523.
- [4] Kaggle. *Natural Language Processing with Disaster Tweets*. <https://www.kaggle.com/competitions/nlp-getting-started>. Consultado en 2026.
- [5] Scikit-learn Developers. *Working With Text Data*. https://scikit-learn.org/stable/tutorial/text_analytics/working_with_text_data.html. Consultado en 2026.

A Correspondencia con la rúbrica

Criterio	Evidencia principal
EDA	Figura 1, <code>eda_por_clase.csv</code>
Limpieza y preprocesamiento	<code>auditoria_limpieza.csv</code> , ejemplos y auditoría de stopwords
N-gramas, frecuencias y probabilidades	Figura 2 y tablas por clase
Modelos clasificadores	Tabla 1, Figuras 4 y 8
Función de clasificación	<code>classify_raw_tweet</code> , <code>predict_tweet.py</code> , modelo persistido
Sentimiento	Figura 5, umbrales y tablas de distribución
Variable de negatividad	Tabla 3 y contraste controlado A/B
Resultados y discusión	Figuras 7 y 9, conclusiones y limitaciones